VISOKA ŠKOLA STRUKOVNIH STUDIJA ZA INFORMACIONE TEHNOLOGIJE

Projektni rad

Predmet: Algoritmi mašinskog učenja

Predmetni nastavnik:

Mr Ana Đokić

Student:

Marko Kostić 369/23

Beograd, 2025/26.

SADRŽAJ

SAŽETAK 3
KLJUČNE REČI 3
UVOD 3
MATERIJALI I METODE 4
SKUP PODATAKA 4
PRIPREMA PODATAKA I EKSPLORATIVNA ANALIZA(EDA) 4
Import biblioteka i učitavanje podataka 4
Prikaz osnovne strukture podataka 4
Identifikacija numeričkih i kategorijskih kolona 5
Provera i obrada nedostajućih vrednosti 5
Provera i uklanjanje duplikata 6
Detekcija i analiza outliera 6
Deskriptivna statistika numeričkih kolona 7
Raspodela vrednosti kategorijskih kolona 7
Vizuelizacije podataka 8
Analiza odnosa između atributa 8
PRIPREMA PODATAKA ZA MODELE 10
Enkodovanje kategorijskih promenljivih 10
Skaliranje podataka 10
Podela podataka na trening i test skup 10
METODE MAŠINSKOG UČENJA 10
Linearna regresija 10
Random Forest regresija 11
REZULTATI I ANALIZA 12
Evalucione metrike 12
Rezultati linearne regresije 12
Rezultati Random Forest regresije 16
Poređenje modela 17
ZAKLJUČAK 18
LITERATURA 19
PRILOZI 20
IZVORNI KOD PROGRAMA 20
SLIKE I TABELE 20
SPISAK SKRAĆENICA I OZNAKA 21
TEHNIČKI ZAHTEVI 22

SAŽETAK

U ovom projektnom radu analiziran je skup podataka *American Housing Data* sa ciljem predviđanja cene nekretnina na osnovu strukturnih karakteristika objekta i lokacijskih/socioekonomskih faktora. Nakon učitavanja podataka izvršena je priprema i eksplorativna analiza (EDA), uključujući deskriptivnu statistiku, vizuelizacije raspodela, proveru nedostajućih vrednosti i analizu ekstremnih vrednosti. Za modelovanje su primenjene dve metode mašinskog učenja: linearna regresija (kao bazni model) i Random Forest regresija (kao nelinearni model). Linearna regresija je dodatno analizirana kroz varijantu sa numeričkim atributima i varijantu sa log-transformacijom ciljne promenljive radi stabilnije procene. Modeli su evaluirani korišćenjem metrika MSE, RMSE i R^2. Rezultati pokazuju da Random Forest postiže znatno bolje performanse u odnosu na linearnu regresiju, što ukazuje na prisustvo nelinearnih odnosa i interakcija između atributa. Na osnovu dobijenih rezultata izvedeni su zaključci o najznačajnijim faktorima koji utiču na cenu i predloženi su pravci za unapređenje modela.

KLJUČNE REČI

- mašinsko učenje
- predviđanje cene nekretnina
- linearna regresija
- Random Forest
- eksplorativna analiza podataka (EDA)
- regresija

UVOD

Predviđanje cene nekretnina predstavlja značajan problem u oblasti analize podataka i mašinskog učenja, s obzirom na veliki broj faktora koji utiču na vrednost stambenih objekata. Cena nekretnine zavisi ne samo od njenih fizičkih karakteristika, kao što su površina ili broj prostorija, već i od lokacije, socioekonomskih uslova i tržišnih okolnosti. Zbog složenosti ovih odnosa, klasični linearni modeli često nisu dovoljni za postizanje zadovoljavajuće tačnosti.

Cilj ovog projektnog rada je analiza i modelovanje podataka o nekretninama sa teritorije Sjedinjenih Američkih Država, sa fokusom na predviđanje prodajne cene. U radu se primenjuju tehnike eksplorativne analize podataka radi boljeg razumevanja strukture skupa podataka, raspodele atributa i međusobnih zavisnosti. Posebna pažnja posvećena je analizi ekstremnih vrednosti i njihovom uticaju na modele.

Za rešavanje problema predviđanja cene primenjene su dve metode mašinskog učenja: linearna regresija, kao bazni i interpretabilan model, i Random Forest regresija, kao nelinearni model sposoban da uhvati složene odnose između atributa. Performanse modela upoređene su korišćenjem standardnih regresionih metrika, a rezultati su analizirani sa ciljem identifikacije najznačajnijih faktora koji utiču na cenu nekretnina.

MATERIJALI I METODE

SKUP PODATAKA

U ovom projektnom radu korišćen je skup podataka *American Housing Data*, koji sadrži informacije o tržištu stambenih nekretnina u Sjedinjenim Američkim Državama. Skup podataka obuhvata **39.981 instancu (redova)** i **14 atributa (kolona)**(Slika 1.).

```
Broj redova i kolona:
(39981, 14)
```

Slika 1. Broj redova i kolona dataseta

Ciljna promenljiva u analizi je **cena nekretnine (Price)**, koja predstavlja kontinuiranu numeričku vrednost i izražena je u monetarnim jedinicama. Ostali atributi opisuju fizičke karakteristike nekretnina, lokacione faktore i socioekonomske uslove.

Skup podataka sadrži kako **numeričke**, tako i **kategorijske** atribute. Numerički atributi uključuju, između ostalog, površinu stambenog prostora (*Living Space*), broj spavaćih soba (*Beds*), broj kupatila (*Baths*), medijalni prihod domaćinstava (*Median Household Income*), kao i geografske koordinate (*Latitude*, *Longitude*). Kategorijski atributi obuhvataju informacije o gradu (*City*), saveznoj državi (*State*) i okrugu (*County*), dok je atribut adrese uklonjen iz daljeg razmatranja zbog nedostatka prediktivne vrednosti.

PRIPREMA PODATAKA I EKSPLORATIVNA ANALIZA(EDA)

Import biblioteka i učitavanje podataka

U okviru pripreme podataka korišćene su standardne Python biblioteke za analizu podataka i mašinsko učenje, uključujući *pandas*, *numpy*, *matplotlib*, *seaborn* i *scikit-learn*. Skup podataka je učitan iz CSV fajla i smešten u *DataFrame* strukturu radi dalje analize.

Prikaz osnovne strukture podataka

Osnovna struktura skupa podataka analizirana je korišćenjem metoda head()(Slika 2.) i info()(Slika 3.), čime je omogućen uvid u prvih nekoliko zapisa, tipove podataka i prisustvo nedostajućih vrednosti. Analiza je pokazala da skup podataka sadrži numeričke i kategorijske atribute.

Prvih 5 redova:

	Zip Code	Price	Beds	Baths	Living Space	Address	City	State	Zip Code Population	Zip Code Density	County	Median Household Income	Latitude	Longitude
0	10013	3999000.0	2	3	1967	74 GRAND ST APT 3	New York	New York	29563	20967.9	New York	370046.0	40.72001	-74.00472
1	10013	3999000.0	2	3	1967	74 GRAND ST APT 3	New York	New York	29563	20967.9	New York	370046.0	40.72001	-74.00472
2	10014	1650000.0	1	1	718	140 CHARLES ST APT 4D	New York	New York	29815	23740.9	New York	249880.0	40.73407	-74.00601
3	10014	760000.0	3	2	1538	38 JONES ST	New York	New York	29815	23740.9	New York	249880.0	40.73407	-74.00601
4	10014	1100000.0	1	1	600	81 BEDFORD ST APT 3F	New York	New York	29815	23740.9	New York	249880.0	40.73407	-74.00601

Slika 2. Prvih pet redova dataseta

```
Informacije o datasetu:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 39981 entries, 0 to 39980
Data columns (total 14 columns):
 #   Column                   Non-Null Count  Dtype
---  ------                   --------------  -----
 0   Zip Code                 39981 non-null  int64
 1   Price                    39981 non-null  float64
 2   Beds                     39981 non-null  int64
 3   Baths                    39981 non-null  int64
 4   Living Space             39981 non-null  int64
 5   Address                  39981 non-null  object
 6   City                     39981 non-null  object
 7   State                    39981 non-null  object
 8   Zip Code Population      39981 non-null  int64
 9   Zip Code Density         39981 non-null  float64
 10  County                   39981 non-null  object
 11  Median Household Income  39979 non-null  float64
 12  Latitude                 39981 non-null  float64
 13  Longitude                39981 non-null  float64
dtypes: float64(5), int64(5), object(4)
memory usage: 4.3+ MB
None
```

Slika 3. Informacije o datasetu

Identifikacija numeričkih i kategorijskih kolona

Atributi su podeljeni na numeričke i kategorijske na osnovu njihovih tipova podataka. Numeričke kolone obuhvataju kontinualne i diskretne vrednosti, kao što su cena, površina stambenog prostora i socioekonomski pokazatelji, dok kategorijske kolone sadrže nominalne informacije o lokaciji nekretnine, kao što su grad, savezna država i okrug(Slika 4.).

```
Numeričke kolone: ['Zip Code', 'Price', 'Beds', 'Baths', 'Living Space', 'Zip Code Population', 'Zip Code Density', 'Median Household Income', 'Latitude', 'Longitude']
Kategorijske kolone: ['Address', 'City', 'State', 'County']
```

Slika 4. Ispis numeričkih i kategorijskih kolona

Provera i obrada nedostajućih vrednosti

Nedostajuće vrednosti su identifikovane proverom broja nenultih vrednosti u svakoj koloni(Slika 5.). Numeričke kolone sa nedostajućim vrednostima popunjene su **medijanom**, čime se umanjuje uticaj ekstremnih vrednosti na imputaciju. Kategorijske kolone popunjene su **najčešćom vrednošću (modom)**. Nakon toga je provereno da li su sve nedostajuće vrednosti popunjene(Slika 6.). Ovim postupkom očuvan je ukupan broj instanci u skupu podataka.

```
Provera nedostajućih vrednosti po kolonama:
Zip Code                   0
Price                      0
Beds                       0
Baths                      0
Living Space               0
Address                    0
City                       0
State                      0
Zip Code Population        0
Zip Code Density           0
County                     0
Median Household Income    2
Latitude                   0
Longitude                  0
```

Slika 5. Broj nedostajućih vrednosti po kolonama

```
Zip Code                  0
Price                     0
Beds                      0
Baths                     0
Living Space              0
Address                   0
City                      0
State                     0
Zip Code Population       0
Zip Code Density          0
County                    0
Median Household Income   0
Latitude                  0
Longitude                 0
```

Slika 6. Broj nedostajućih vrednosti po kolonama nakon popunjavanja

Provera i uklanjanje duplikata

Skup podataka je proveravan na prisustvo dupliranih instanci. Analiza je pokazala postojanje **962 duplirana zapisa**, koji su predstavljali identične redove u svim atributima. Duplikati su uklonjeni iz skupa podataka kako bi se obezbedila konzistentnost i pouzdanost analize. Nakon uklanjanja duplikata, skup podataka više nije sadržao ponovljene instance. Nakon toga je provereno i dobijena je potvrda da su svi duplikati uklonjeni(Slika 7.).

```
Broj duplikata: 962
Broj duplikata nakon brisanja: 0
Duplikati su uspešno uklonjeni.
```

Slika 7. Ispis broja duplikata i potvrda da su uklonjeni

Detekcija i analiza outliera

Prisustvo ekstremnih vrednosti analizirano je kroz vizuelizacije numeričkih atributa i deskriptivnu statistiku(Slika 8.). Uočeno je postojanje izraženih outliera, posebno kod ciljne promenljive(Slika 9.) i pojedinih numeričkih atributa. Outlieri **nisu uklonjeni iz skupa podataka**, već su korišćeni puni podaci za treniranje modela, dok su za potrebe vizualizacije prikazivani i u ograničenom opsegu do 99. percentila radi bolje preglednosti(Slika 10).

```
Donja granica: -341250.00
Gornja granica: 1275150.00
Broj outliera: 3492
```

Slika 8. Statistika za outliere

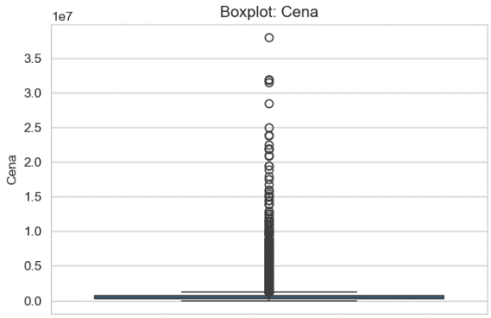

Slika 9. Prisustvo outliera kod ciljne promenljive(Boxplot)

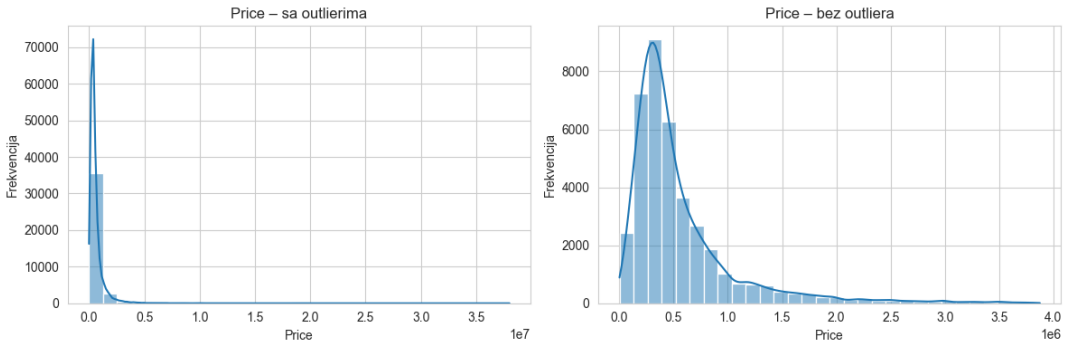

Slika 10. Primer prikaza distribucije sa i bez outliera(na primeru ciljne promenljive)

Deskriptivna statistika numeričkih kolona

Za numeričke kolone izračunate su osnovne deskriptivne statistike, uključujući aritmetičku sredinu, medijanu, standardnu devijaciju, minimum i maksimum, kvantile(Slika 11.). Analiza je pokazala da većina numeričkih atributa ima asimetrične raspodele, sa izraženim desnim repovima, što je naročito izraženo kod ciljne promenljive(Slika 10.).

Statistički rezime:

	Zip Code	Price	Beds	Baths	Living Space	Zip Code Population	Zip Code Density	Median Household Income	Latitude	Longitude
count	39981.000000	3.998100e+04	39981.000000	39981.000000	39981.000000	39981.000000	39981.000000	39979.000000	39981.000000	39981.000000
mean	64833.391336	6.227771e+05	3.171682	2.466572	1901.522723	37726.201996	2379.412483	110837.259861	36.435668	-98.080576
std	25614.601116	9.469793e+05	1.308796	1.323042	1211.307257	18672.647445	2946.574792	47309.055715	4.446862	15.061145
min	10013.000000	1.800000e+03	1.000000	1.000000	2.000000	0.000000	0.000000	27475.000000	25.729830	-122.826870
25%	40215.000000	2.650000e+05	3.000000	2.000000	1200.000000	24465.000000	902.400000	76640.000000	33.239850	-111.636310
50%	74136.000000	3.999000e+05	3.000000	2.000000	1639.000000	35049.000000	1588.700000	100405.000000	36.166620	-96.839680
75%	85730.000000	6.749900e+05	4.000000	3.000000	2265.000000	46816.000000	2736.800000	135075.000000	39.283090	-85.656980
max	98199.000000	3.800000e+07	54.000000	66.000000	74340.000000	116469.000000	58289.600000	900203.000000	47.742370	-73.704510

Slika 11. Deskriptivna statistika numeričkih kolona

Raspodela vrednosti kategorijskih kolona

Raspodela vrednosti kategorijskih atributa analizirana je pomoću ispisa distribucije kategorijskih kolona(Slika 12.), čime je omogućen uvid u zastupljenost pojedinih kategorija. Ova analiza pokazala je neravnomernu raspodelu kategorija, što je očekivano s obzirom na geografsku prirodu podataka.

```
Distribucija kolone City:
City
Mesa              894
Charlotte         885
Virginia Beach    879
Denver            878
Albuquerque       875
                 ...
Kerman              1
San Leandro         1
Santa Clara         1
Campbell            1
Milpitas            1
```

Slika 12. Distribucija kategorijske kolone(na konkretnom primeru kolone City)

Vizuelizacije podataka

Vizuelna analiza podataka obuhvatila je boxplot ciljne promenljive, histograme numeričkih atributa koji su od veće važnosti kako bi se izbegao preveliki broj histograma. Takođe su prikazani i hisogrami odnosa važnijih numeričkih atributa i cene, sa izuzimanjem *Beds* i *Baths* atributa jer su diskretni i scatter se preklapa i ne daje jasan trend. Histogrami su korišćeni za analizu raspodele vrednosti, dok je boxplot omogućio uvid u prisustvo i opseg ekstremnih vrednosti(Slika 9.). Za pojedine numeričke atribute, histogrami su prikazani i u ograničenom opsegu radi jasnijeg uvida u dominantni deo podataka(Slika 10.).

Analiza odnosa između atributa

Odnosi između numeričkih atributa i ciljne promenljive analizirani su korišćenjem scatterplotova, pri čemu su posebno razmatrani atributi *Living Space* i *Median Household Income*(Slika 13.). Korelacije između numeričkih atributa prikazane su pomoću korelacione matrice i *heatmap* vizualizacije(Slika 14.). Analiza je ukazala na postojanje umerenih do jakih veza između pojedinih atributa(*Living Space*, *Median Household Income, Beds* i *Baths*) i cene, kao i na potencijalne nelinearne odnose.

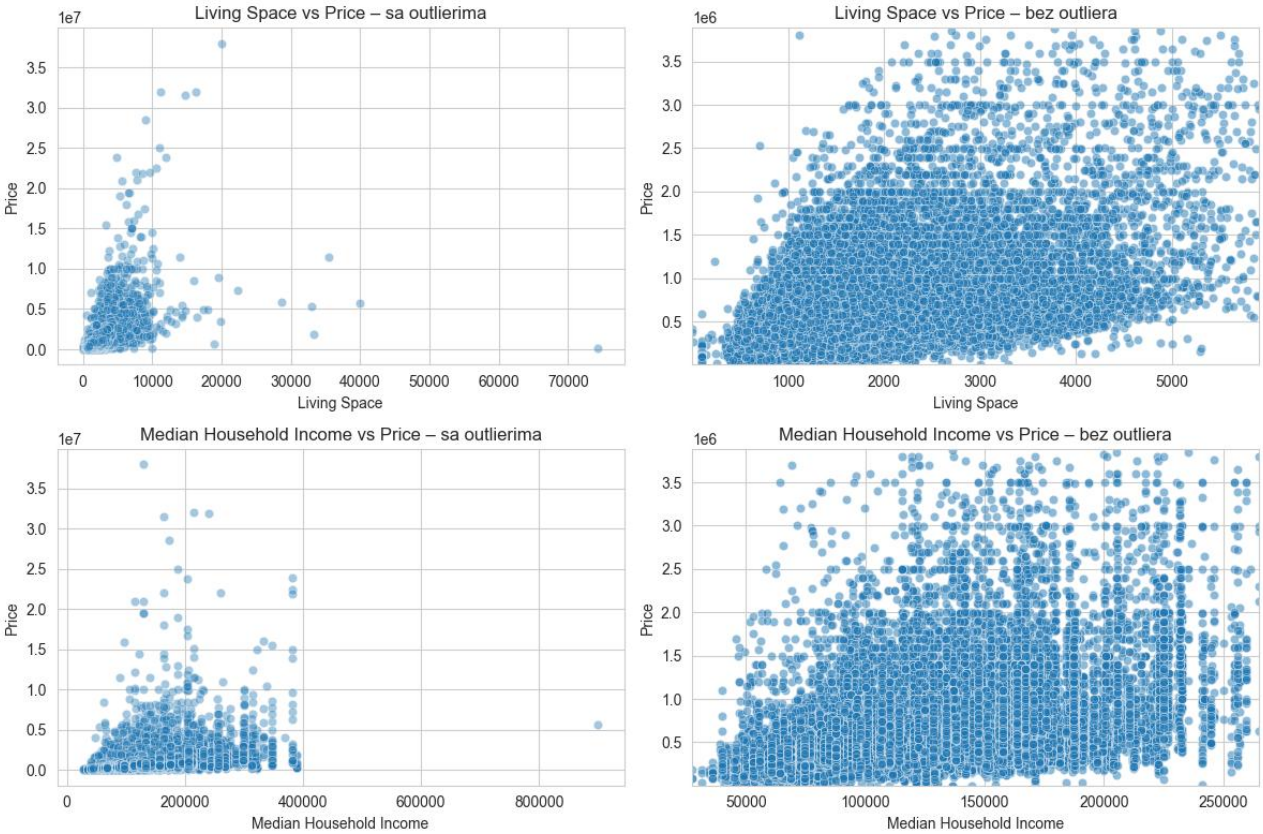

Slika 13. Prikaz odnosa atributa Living Space – Price i Median Household Income - Price

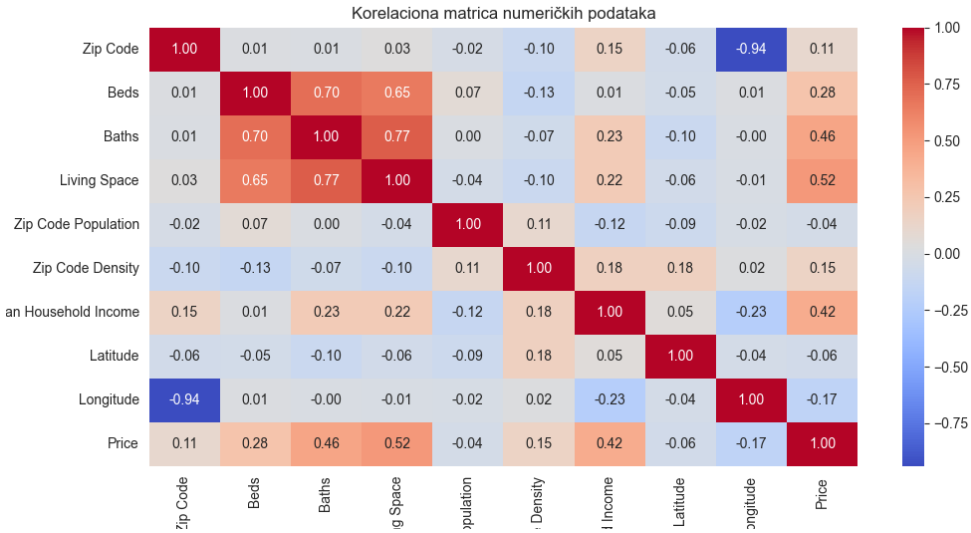

Slika 14. Korelaciona matrica(heatmap) numeričkih kolona

PRIPREMA PODATAKA ZA MODELE

Enkodovanje kategorijskih promenljivih

Nakon selekcije kategorijskih atributa u skupu podataka koji su bitni za model(vrednosti atributa *Adress* nisu uključene u model jer je procenjeno da nemaju toliko veliki uticaj na cenu kao ostali atributi i njihovo one-hot enkodovanje dovelo do visokodimenzionalnog prostora i potencijalnog prenaučenja), transformisani su u numerički oblik kako bi mogli biti korišćeni u modelima mašinskog učenja. Za tu svrhu primenjena je tehnika *one-hot encoding*, kojom se svaka kategorijska vrednost predstavlja posebnom binarnom promenljivom. Ovakav pristup izabran je kako bi se izbeglo uvođenje veštačkog ordinalnog odnosa između kategorija, što bi moglo negativno uticati na performanse modela.

Skaliranje podataka

Skaliranje podataka primenjeno je u modelima linearne regresije, gde su numerički atributi standardizovani korišćenjem *StandardScaler* metode. Na ovaj način obezbeđeno je da svi atributi imaju istu skalu, čime se sprečava dominacija atributa sa većim numeričkim opsegom. Kod Random Forest modela skaliranje nije primenjeno, s obzirom na to da ovaj algoritam nije osetljiv na razliku u skalama ulaznih atributa.

Podela podataka na trening i test skup

Skup podataka podeljen je na trening i test skup korišćenjem metode *train-test split*. Trening skup korišćen je za učenje modela, dok je test skup služio za evaluaciju performansi. Podela je izvršena u odnosu **80% za trening i 20% za test**, uz fiksiranje slučajnog semena radi obezbeđivanja reproduktivnosti rezultata.

METODE MAŠINSKOG UČENJA

U ovom radu primenjene su dve metode mašinskog učenja za rešavanje problema predviđanja cene nekretnina: **linearna regresija** i **Random Forest regresija**. Linearna regresija korišćena je kao bazni model, dok je Random Forest primenjen kao napredniji nelinearni model.

Linearna regresija

Linearna regresija predstavlja jedan od osnovnih regresionih algoritama, koji modeluje odnos između ulaznih atributa i ciljne promenljive kao linearnu kombinaciju ulaza. Cilj algoritma je pronalaženje koeficijenata koji minimizuju grešku između stvarnih i predviđenih vrednosti, najčešće korišćenjem metode najmanjih kvadrata. Zbog svoje jednostavnosti i interpretabilnosti, linearna regresija često služi kao bazni model u regresionim problemima.

Korišćeni parametri:

U ovom radu korišćena je implementacija linearne regresije bez regularizacije, sa podrazumevanim parametrima biblioteke *scikit-learn*. Model je treniran nad standardizovanim numeričkim atributima i kategorijskim koji imaju uticaja na ciljnu promenljivu, a dodatno su razmatrane i varijante sa samo numeričkim atributima i log-transformisanom ciljnom promenljivom radi stabilnije procene.

Razlog izbora metode:

Linearna regresija izabrana je kao polazni model zbog svoje jednostavnosti, brzine treniranja i mogućnosti interpretacije koeficijenata. Pored toga, model omogućava procenu u kojoj meri je problem linearan i služi kao referenca za poređenje sa složenijim modelima.

Random Forest regresija

Random Forest regresija je ansambl metoda zasnovana na velikom broju stabala odlučivanja, gde se konačna predikcija dobija agregacijom predikcija pojedinačnih stabala. Algoritam uvodi slučajnost kroz izbor podskupova podataka i atributa, čime se smanjuje varijansa modela i poboljšava generalizacija. Zbog svoje sposobnosti da modeluje nelinearne odnose, Random Forest je pogodan za složene regresione probleme.

Korišćeni parametri:

Random Forest model treniran je korišćenjem **200 stabala odlučivanja** (*n_estimators = 200*). Izabran je umeren broj stabala koji obezbeđuje dobar balans između performansi modela i vremena treniranja, bez potrebe za dodatnom optimizacijom. Ostali parametri, uključujući maksimalnu dubinu stabala i minimalan broj uzoraka po čvoru, ostavljeni su na podrazumevanim vrednostima biblioteke *scikit-learn*. Za obezbeđivanje reproduktivnosti rezultata korišćeno je fiksno slučajno seme (*random_state = 42*). Model je treniran na kombinaciji numeričkih i odabranih kategorijskih atributa, pri čemu su kategorijski atributi prethodno transformisani metodom one-hot encoding.

Razlog izbora metode:

Random Forest regresija izabrana je zbog svoje robusnosti na outliere, sposobnosti modelovanja nelinearnih odnosa i interakcija između atributa, kao i zbog dobrih performansi na realnim skupovima podataka. Ova metoda omogućava i procenu značaja pojedinih atributa, što dodatno doprinosi interpretaciji rezultata.

REZULTATI I ANALIZA

U ovom poglavlju prikazani su i analizirani rezultati dobijeni primenom linearne regresije i Random Forest regresije na problem predviđanja cene nekretnina. Modeli su evaluirani na test skupu podataka korišćenjem standardnih regresionih metrika, a dobijeni rezultati su upoređeni radi procene njihove efikasnosti.

EVALUCIONE METRIKE

Za evaluaciju performansi modela korišćene su sledeće metrike:

- srednja kvadratna greška (MSE),
- koren srednje kvadratne greške (RMSE),
- koeficijent determinacije (R^2).

Ove metrike omogućavaju kvantitativnu procenu tačnosti predikcija, kao i objašnjenje koliki deo varijanse ciljne promenljive model uspeva da objasni.

REZULTATI LINEARNE REGRESIJE

Linearna regresija je u ovom radu testirana kroz **tri različite varijante**, sa ciljem ispitivanja uticaja izbora atributa i transformacije ciljne promenljive na performanse modela.

Prva varijanta linearne regresije trenirana je korišćenjem **numeričkih atributa u kombinaciji sa odabranim kategorijskim atributima**, koji su prethodno transformisani metodom *one-hot encoding*. Uprkos uključivanju dodatnih informacija o lokaciji, dobijeni rezultati pokazali su nezadovoljavajuće performanse modela, sa **negativnom vrednošću koeficijenta determinacije (R^2)**(Slika 15.). Ovo ukazuje na to da linearni model nije uspeo da iskoristi informacije iz kategorijskih atributa na adekvatan način, kao i da pretpostavka linearnosti nije bila ispunjena. Scatterplot prikaz stvarnih i predviđenih cena ukazao je na veliko rasipanje tačaka, kao i na pojavu **nerealnih negativnih predikcija cene**(Slika 16.), što predstavlja poznato ograničenje linearnog regresionog modela.

```
Model sa numeričkim i važnim kategorijskim kolonama:
MSE: 1851522037351.89
RMSE: 1360706.45
R² score: -0.6561
```

Slika 15. Rezultati modela linearne regresije sa korišćenjem numeričkih atributa u kombinaciji sa odabranim kategorijskim atributima

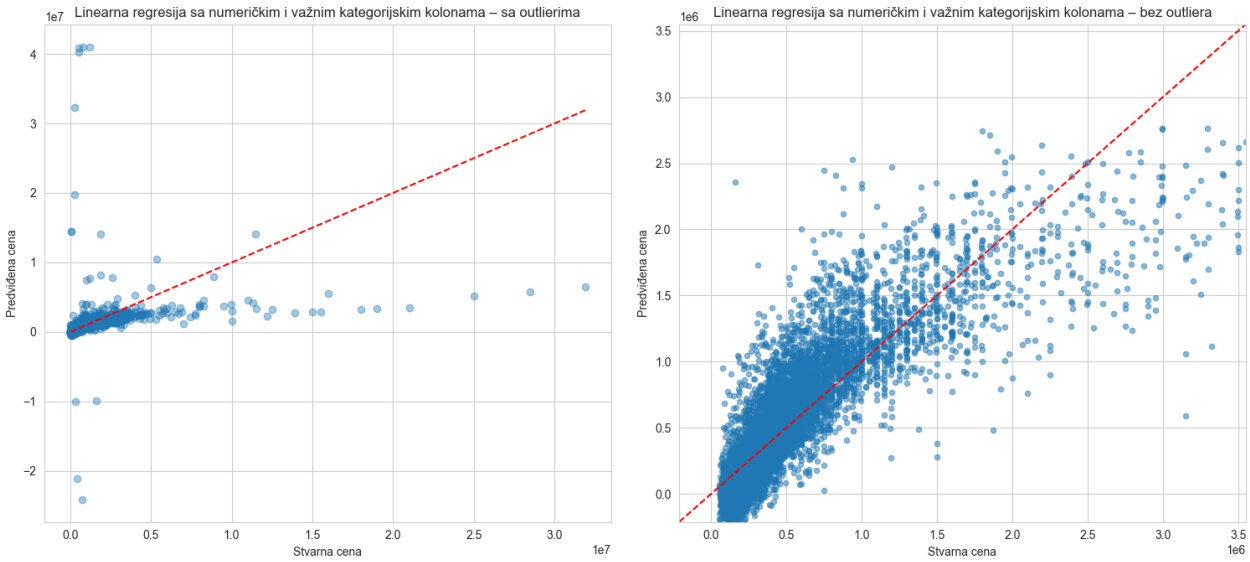

Slika 16. Vizelizacija rezultata modela linearne regresije sa korišćenjem numeričkih atributa u kombinaciji sa odabranim kategorijskim atributima

Druga varijanta linearne regresije primenjena je korišćenjem **isključivo numeričkih atributa**, bez dodatne transformacije ciljne promenljive. Rezultati ovog modela takođe su pokazali vrlo slabe performanse, ovaj put sa pozitvnim R^2 koeficijentom(Slika 17.), ali relativno niskom vrednosti, i značajnim odstupanjima između stvarnih i predviđenih vrednosti. Scatterplot prikaz stvarnih i predviđenih cena ukazao je na veliko rasipanje tačaka, kao i na pojavu **nerealnih negativnih predikcija cene**(Slika 18.).

```
Model sa samo numeričkim kolonama:
MSE: 684382218727.21
RMSE: 827273.97
R² score: 0.3879
```

Slika 17. Rezultati modela linearne regresije sa korišćenjem isključivo numeričkih atributa

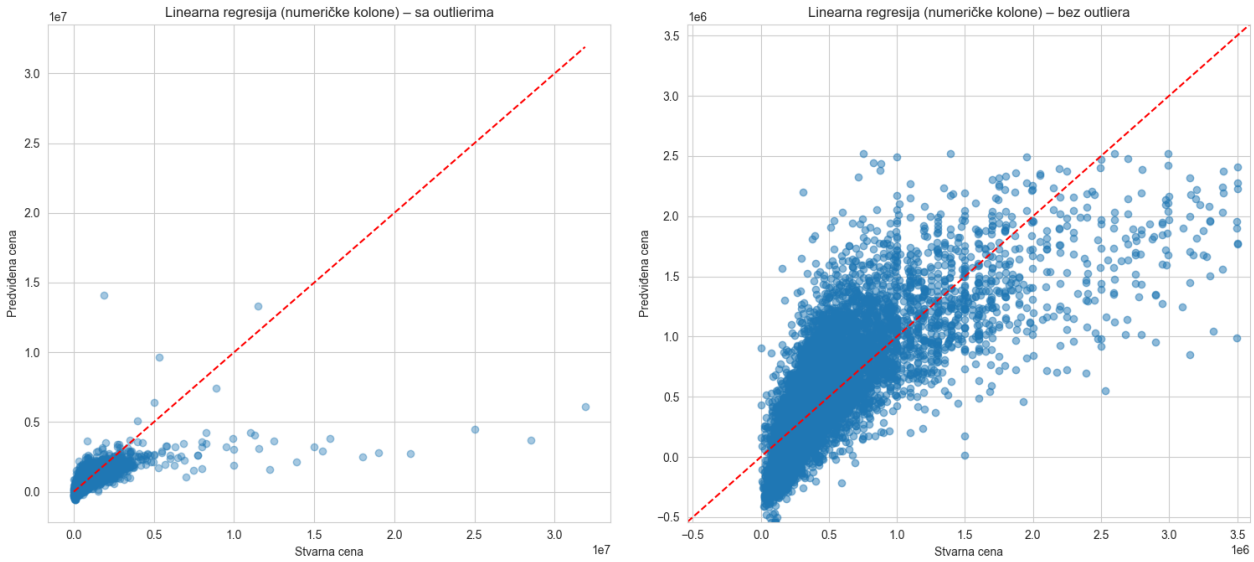

Slika 18. Vizuelizacija rezultata modela linearne regresije sa korišćenjem isključivo numeričkih atributa

U trećoj varijanti linearne regresije korišćeni su **numerički atributi uz primenu log-transformacije ciljne promenljive**. Ova transformacija dovela je do stabilnijih predikcija i poboljšanja evaluacionih metrika u poređenju sa prethodne dve varijante(Slika 19.). Scatterplot prikaz log-transformisanih stvarnih i predviđenih vrednosti pokazao je bolju koncentraciju tačaka oko idealne dijagonale, što ukazuje na delimično poboljšanje performansi modela(Slika 20.). Ipak, i pored ovog unapređenja, linearna regresija nije dostigla nivo tačnosti nelinearnih modela.

```
Model sa samo numeričkim kolonama i log-transformacijom ciljne promenljive:
MSE: 0.25
RMSE: 0.50
R² score: 0.6217
```

Slika 19. Rezultati modela linearne regresije sa korišćenjem numeričkih atributa uz primenu log-transformacije ciljne promenljive

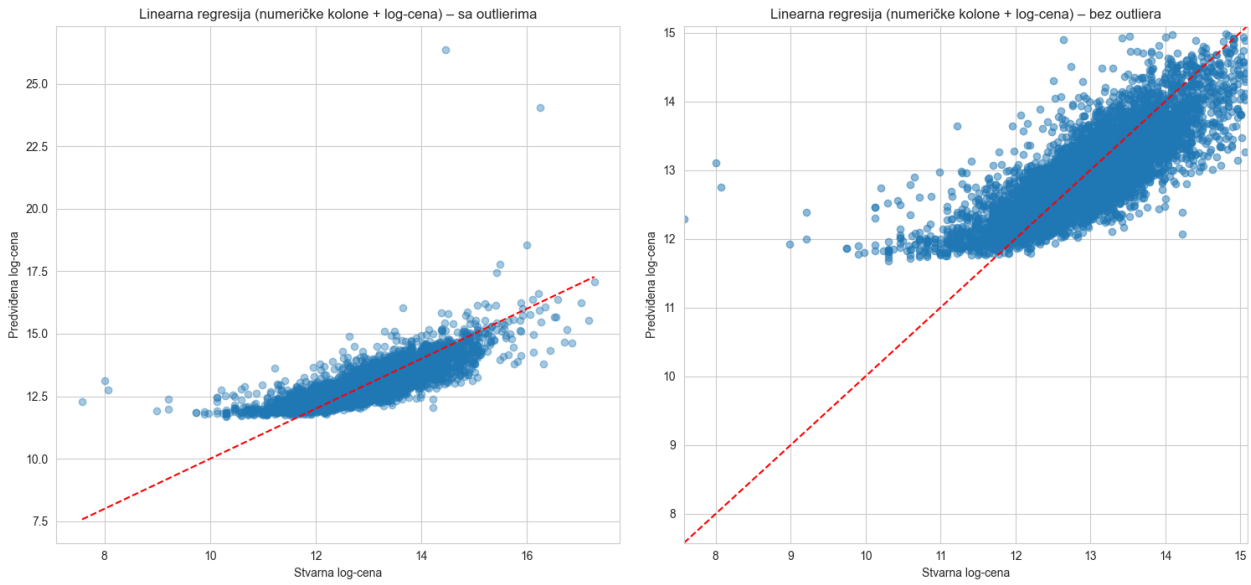

Slika 20. Vizuelizacija rezultata modela linearne regresije sa korišćenjem numeričkih atributa uz primenu log-transformacije ciljne promenljive

Rezultati sva tri pristupa linearne regresije jasno ukazuju na to da izbor atributa i transformacija ciljne promenljive mogu uticati na performanse modela, ali i da linearna regresija, čak i u optimalnijoj konfiguraciji, nije dovoljno fleksibilna za modelovanje složenih odnosa prisutnih u podacima o cenama nekretnina.

U cilju jasnijeg uvida u raspodelu podataka i ponašanje modela, scatterplot prikazi stvarnih i predviđenih vrednosti prikazani su kako u originalnom obliku, tako i u zumiranom opsegu bez ekstremnih vrednosti, čime je omogućen detaljniji prikaz dominantnog dela podataka.

Analiza koeficijenata sprovedena je isključivo za varijantu linearne regresije sa numeričkim atributima i log-transformisanom ciljnom promenljivom, s obzirom na to da ova konfiguracija daje najstabilnije i interpretabilne rezultate. Analiza koeficijenata linearne regresije pokazala je da **najveći pozitivan uticaj na predviđenu cenu ima atribut *Median Household Income***, što ukazuje na snažnu povezanost socioekonomskih faktora i cene nekretnina. Značajan pozitivan uticaj imaju i atributi *Living Space* i *Baths*, koji predstavljaju fizičke karakteristike objekta. Geografski atributi, poput *Longitude* i *Latitude*, imaju negativan, ali slabiji uticaj, dok su *Zip Code Density* i *Zip Code Population* pokazali relativno mali doprinos modelu. Atribut *Beds* ima gotovo zanemarljiv uticaj, što sugeriše da broj spavaćih soba sam po sebi ne predstavlja snažan prediktor cene kada su ostali atributi uključeni u model(Slika 21.).

```
Koeficijenti modela sa samo numeričkim kolonama i log-cenom:
                   Atribut  Koeficijent
3  Median Household Income     0.342098
2                    Baths     0.208082
0             Living Space     0.207155
7                Longitude    -0.176786
5          Zip Code Density     0.156060
6                 Latitude    -0.093367
4      Zip Code Population     0.018388
1                     Beds    -0.008547
```

Slika 21. Koeficijenti modela sa samo numeričkim kolonama i log-cenom

REZULTATI RANDOM FOREST REGRESIJE

Random Forest regresija primenjena je kao nelinearni model sposoban da modeluje složenije odnose između atributa. Model je treniran na kombinaciji numeričkih i odabranih kategorijskih atributa. Dobijeni rezultati pokazuju značajno poboljšanje u odnosu na linearnu regresiju, sa vrednošću **R^2 koeficijenta od približno 0.69**, što ukazuje da model uspeva da objasni oko 69% varijanse ciljne promenljive(Slika 22.).

```
Random Forest Regressor (numeričke + važne kategorijske kolone):
MSE: 344738379550.83
RMSE: 587144.26
R² score: 0.6916
```

Slika 22. Rezultati modela Random Forest regresije

Scatterplot stvarnih i predviđenih vrednosti pokazuje znatno bolju koncentraciju tačaka oko idealne dijagonale u poređenju sa linearnim modelom, što ukazuje na bolju tačnost predikcija i manju grešku modela. Takođe, Random Forest model ne proizvodi nerealne negativne predikcije cene, što predstavlja dodatnu prednost u odnosu na linearnu regresiju(Slika 23.).

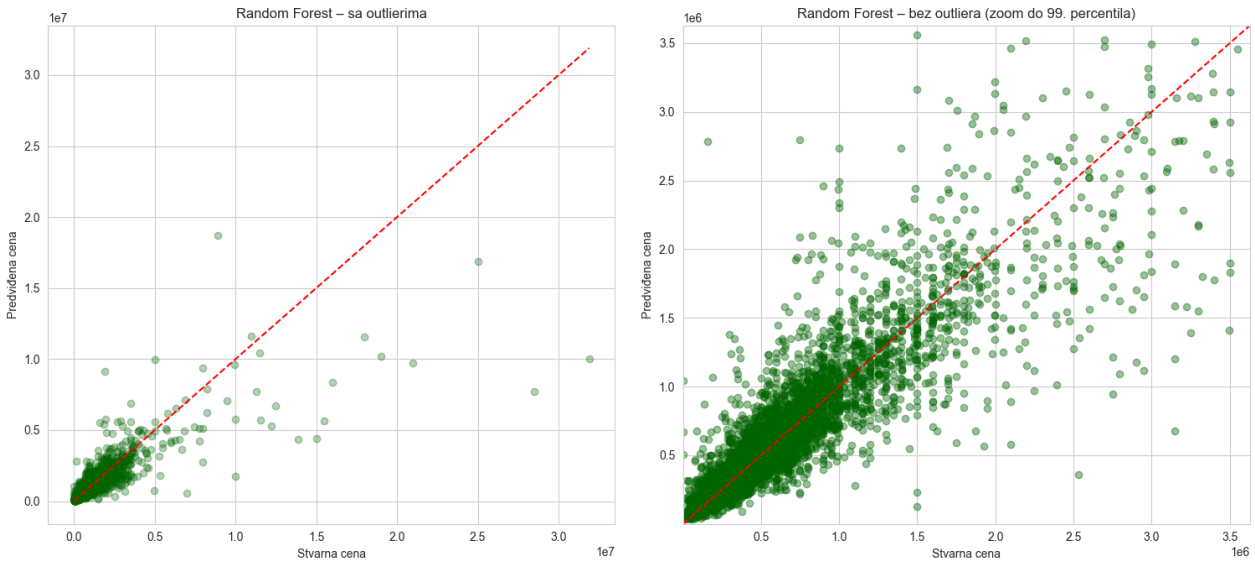

Slika 23. Vizuelizacija rezultata modela Random Forest regresije

Rezultati potvrđuju da Random Forest uspešnije hvata nelinearne odnose i interakcije između atributa, što ga čini pogodnijim modelom za predviđanje cene nekretnina.

Pored evaluacionih metrika, analizirana je i **važnost atributa** dobijena Random Forest modelom. Rezultati pokazuju da najveći doprinos predviđanju cene ima atribut *Living Space*, što je u skladu sa očekivanjima, s obzirom na to da površina nekretnine direktno utiče na njenu vrednost. Značajan uticaj imaju i atributi *Baths* i *Median Household Income*, koji odražavaju kvalitet i socioekonomski kontekst lokacije. Geografski atributi, poput *Latitude* i *Longitude*, imaju umeren doprinos, dok su pojedini kategorijski atributi, kao što su *State_California* i specifične vrednosti atributa *City*, imali manji, ali merljiv uticaj. Rezultati ukazuju na to da Random Forest uspešno kombinuje fizičke karakteristike nekretnine i informacije o lokaciji prilikom predviđanja cene(Slika 24.).

```
Najvažniji atributi Random Forest modela:
                     Atribut   Važnost
3               Living Space  0.252221
2                      Baths  0.230630
6    Median Household Income  0.167998
7                   Latitude  0.059458
251         State_California  0.045255
5           Zip Code Density  0.038577
0                   Zip Code  0.030286
8                  Longitude  0.028633
1                       Beds  0.020685
122            City La Jolla  0.020195
```

Slika 24. Najvažniji atributi Random Forest modela

POREĐENJE MODELA

Uporedna analiza modela jasno pokazuje da Random Forest regresija ostvaruje znatno bolje performanse u odnosu na linearnu regresiju, kako u pogledu vrednosti R^2 koeficijenta, tako i u pogledu smanjenja greške predikcije. Dok linearna regresija služi kao koristan referentni model, njene performanse su ograničene zbog pretpostavke linearnosti odnosa. Nasuprot tome, Random Forest se pokazao kao robusniji i precizniji model za dati skup podataka.

Zaključak poređenja:
Za problem predviđanja cene nekretnina, Random Forest regresija predstavlja znatno efikasniji pristup u odnosu na linearnu regresiju.

ZAKLJUČAK

U ovom projektnom radu analiziran je skup podataka o stambenim nekretninama sa ciljem predviđanja njihove prodajne cene primenom metoda mašinskog učenja. Nakon sprovedene pripreme podataka i eksplorativne analize, primenjeni su modeli linearne regresije i Random Forest regresije, a njihove performanse upoređene su korišćenjem standardnih evaluacionih metrika.

Rezultati su pokazali da linearna regresija, iako jednostavna i interpretabilna, ne uspeva da adekvatno modeluje složene odnose prisutne u podacima, što se ogleda u slabim evaluacionim rezultatima i pojavi nerealnih predikcija. Uvođenjem log-transformacije ciljne promenljive postignuto je delimično poboljšanje, ali su ograničenja linearnog pristupa i dalje ostala prisutna. Sa druge strane, Random Forest regresija ostvarila je znatno bolje performanse, sa značajno većom vrednošću koeficijenta determinacije i manjom greškom predikcije. Razlog boljih rezultata Random Forest modela leži u njegovoj sposobnosti da modeluje nelinearne odnose i interakcije između atributa, kao i u njegovoj robusnosti na ekstremne vrednosti.

Iako dobijeni rezultati ukazuju na dobru prediktivnu moć Random Forest modela, rad ima određena ograničenja. Pre svega, korišćeni skup podataka ne sadrži vremensku dimenziju, što onemogućava analizu promena cena kroz vreme. Takođe, nisu razmatrani svi potencijalni faktori koji mogu uticati na cenu nekretnina, kao što su makroekonomski pokazatelji ili detaljniji podaci o stanju objekta.

Kao mogući pravci za unapređenje rada mogu se navesti optimizacija hiperparametara Random Forest modela, primena naprednijih algoritama kao što su gradient boosting metode, kao i uključivanje dodatnih relevantnih atributa. Takođe, buduća istraživanja mogla bi obuhvatiti i vremensku analizu podataka, kao i poređenje sa drugim regresionim modelima.

LITERATURA

- Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324

- Đokić, A. (2025).
  Algoritmi mašinskog učenja – Predavanja.
  Materijali sa kursa Algoritmi mašinskog učenja.
  Visoka škola strukovnih studija za informacione tehnologije.

- Đokić, A. (2025).
  Algoritmi mašinskog učenja – Vežbe.
  Materijali sa kursa Algoritmi mašinskog učenja.
  Visoka škola strukovnih studija za informacione tehnologije.

PRILOZI

IZVORNI KOD PROGRAMA

U ovom prilogu dat je kompletan izvorni kod Python skripte korišćene za pripremu podataka, eksplorativnu analizu, treniranje i evaluaciju modela mašinskog učenja u okviru ovog rada. Kod obuhvata implementaciju linearne regresije i Random Forest regresije, kao i sve pripadajuće vizualizacije i evaluacione metrike.

Izvorni kod dostavljen je u elektronskom obliku kao poseban fajl.

SLIKE I TABELE

- Slika 1. – Broj redova i kolona dataseta
- Slika 2. – Prvih pet redova dataseta
- Slika 3. – Informacije o datasetu
- Slika 4. - Ispis numeričkih i kategorijskih kolona
- Slika 5. – Broj nedostajućih vrednosti po kolonama
- Slika 6. - Broj nedostajućih vrednosti po kolonama nakon popunjavanja
- Slika 7. - Ispis broja duplikata i potvrda da su uklonjeni
- Slika 8. - Statistika za outliere
- Slika 9. - Prisustvo outliera kod ciljne promenljive(Boxplot)
- Slika 10. - Primer prikaza distribucije sa i bez outliera(na primeru ciljne promenljive)
- Slika 11. - Deskriptivna statistika numeričkih kolona
- Slika 12. - Distribucija kategorijske kolone(na konkretnom primeru kolone City)
- Slika 13. - Prikaz odnosa atributa Living Space – Price i Median Household Income - Price
- Slika 14. - Korelaciona matrica(heatmap) numeričkih kolona
- Slika 15. - Rezultati modela linearne regresije sa korišćenjem numeričkih atributa u kombinaciji sa odabranim kategorijskim atributima
- Slika 16. - Vizelizacija rezultata modela linearne regresije sa korišćenjem numeričkih atributa u kombinaciji sa odabranim kategorijskim atributima
- Slika 17. - Rezultati modela linearne regresije sa korišćenjem isključivo numeričkih atributa
- Slika 18. - Vizuelizacija rezultata modela linearne regresije sa korišćenjem isključivo numeričkih atributa
- Slika 19. - Rezultati modela linearne regresije sa korišćenjem numeričkih atributa uz primenu log-transformacije ciljne promenljive
- Slika 20. - Vizuelizacija rezultata modela linearne regresije sa korišćenjem numeričkih atributa uz primenu log-transformacije ciljne promenljive
- Slika 21. - Koeficijenti modela sa samo numeričkim kolonama i log-cenom
- Slika 22. - Rezultati modela Random Forest regresije
- Slika 23. - Vizuelizacija rezultata modela Random Forest regresije
- Slika 24 - Najvažniji atributi Random Forest modela

SPISAK SKRAĆENICA I OZNAKA

Skraćenica	Puni naziv (engleski)	Prevod
EDA	Exploratory Data Analysis	Eksplorativna analiza podataka
LR	Linear Regression	Linearna regresija
RF	Random Forest	"Slučajna šuma"
MSE	Mean Squared Error	Srednja kvadratna greška
RMSE	Root Mean Squared Error	Kvadratni koren srednje kvadratne greške
R^2	Coefficient of Determination	Koeficijent determinacije

TEHNIČKI ZAHTEVI

- Programski jezik: Python
- Razvojno okruženje: VS Code / Anaconda
- Biblioteke: pandas, numpy, matplotlib, seaborn, scikit-learn